UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ingeniería Industrial y de Sistemas

Maestría en Inteligencia Artificial



INFORME DE SPRINT — SEMANA 6

Análisis exploratorio, ingeniería de características y evaluación comparativa de modelos de regresión para la predicción de la carga de primera falla en estructuras pantográficas

Trabajo de Investigación II

Estudiante: Melissa Dessire Aylas Barranca

Docente: Glen Dario Rodríguez Rafael

Periodo: 2026-II

Ciclo y sección: Cuarto ciclo · Sección B

Lima, Perú — 2026

Índice

Resumen **1**

1. Introducción **1**

2. Contexto experimental y comprensión de los datos **2**

3. Metodología de análisis exploratorio **4**

4. Feature Engineering guiado por EDA **6**

5. Diseño experimental y protocolo de validación **9**

6. Resultados experimentales comparativos **10**

7. Discusión crítica **13**

8. Conclusiones y decisiones del sprint **15**

9. Reproducibilidad **16**

Referencias **17**

A. Errores por configuración nominal **18**

B. Comparación secundaria de regresores **18**

C. Fuentes documentales y archivos de verificación **19**

Resumen

La estimación de la carga de primera falla de estructuras pantográficas exige relacionar la geometría previa al ensayo con un evento local de rotura, distinto del colapso terminal. Este sprint consolida datos experimentales de retículos de poliamida sometidos a tracción con carga y descarga y evalúa si una representación geométrica derivada reduce el error de regresión. El análisis exploratorio identificó escalas heterogéneas, dependencias de diseño y asociaciones que cambian al condicionar por familia. Sobre esa evidencia se compararon cuatro conjuntos acumulativos: geometría original, adición de dos segundos momentos de área, incorporación de una razón logarítmica de volúmenes y retirada de un bloque de descriptores dependientes. Se mantuvieron Ridge y sus parámetros fijos, con preprocesamiento ajustado exclusivamente en entrenamiento. La validación reservó grupos de configuración nominal y, como comprobación de transferencia, familias completas. En el protocolo principal, los momentos redujeron el MAE de 13,247 a 12,835 N, una diferencia de 0,412 N (3,11 %); la razón adicional elevó el MAE a 12,914 N y la reducción de columnas a 17,035 N. Al reservar familias completas, la variante con momentos obtuvo MAE de 57,654 N y $R^2 = -0{,}060$, lo que limita la extrapolación. La mejora inicial no satisface todos los criterios de adopción: se conserva la referencia y los momentos permanecen en evaluación. Las comparaciones son exploratorias por el uso del EDA completo para proponer características y por la ausencia de validación externa. La contribución del sprint es una decisión trazable sobre representaciones, incluidos sus resultados negativos.

Palabras clave: estructuras pantográficas; primera falla; ingeniería de características; regresión Ridge; validación por grupos.

1. Introducción

1.1 Contextualización del problema

Las estructuras pantográficas son retículos constituidos por fibras conectadas mediante pivotes. La campaña estudiada utiliza dos conjuntos ortogonales de fibras, situados en planos paralelos y unidos por conectores cilíndricos deformables. Su respuesta depende tanto del material constitutivo como de la arquitectura, las dimensiones de los elementos y la interacción entre ellos [1, 2]. En la literatura, la extensión y flexión de las fibras y la torsión de las conexiones aparecen como mecanismos de modelos discretos; su presencia en un modelo mecánico no demuestra cuál domina cada rotura experimental [3].

Durante un ensayo de tracción se impone un desplazamiento y se registra la fuerza correspondiente. La primera falla identifica un evento local de rotura, mientras que la estructura puede conservar capacidad de transmisión de carga después de ese evento. Predecir la fuerza asociada permite estudiar una respuesta anterior a la rotura terminal. El presente trabajo aborda esa estimación mediante regresión supervisada sobre descriptores geométricos previos al ensayo.

1.2 Problema de investigación

Una colección de dimensiones no constituye, por sí sola, una representación adecuada para cualquier regresor. Las variables presentan escalas distintas, dependencias impuestas por el diseño y asociaciones con la respuesta que pueden cambiar al comparar arquitecturas. Además, un

modelo lineal no genera automáticamente productos o potencias entre sus entradas. La pregunta aplicada del sprint es: *¿en qué medida las características geométricas derivadas permiten reducir el error de predicción de la carga de primera falla respecto al uso de las variables originales?*

1.3 Objetivo del sprint

Evaluar el aporte de las características ya implementadas mediante una comparación controlada entre cuatro representaciones de datos, manteniendo constantes el regresor Ridge, sus parámetros y las particiones. El informe consolida la evidencia existente: relaciona los hallazgos exploratorios con las transformaciones, contrasta las predicciones fuera de muestra e identifica qué decisiones pueden sostenerse sin atribuir causalidad a asociaciones observacionales.

1.4 Preguntas específicas

Se examinan cinco preguntas verificables: ¿qué problemas de calidad y dependencias geométricas condicionan las entradas?; ¿qué fundamento tienen los momentos de sección y la razón logarítmica de volúmenes?; ¿cuánto cambia el error con cada intervención?; ¿persiste el resultado al reservar configuraciones y familias completas?; y ¿conviene adoptar una variante, conservar la referencia o mantener una propuesta en evaluación? Las respuestas se sustentan en tablas, predicciones y registros de la ejecución, sin sustituirlas por métricas de ajuste sobre entrenamiento.

1.5 Alcance

El dominio corresponde a la campaña experimental disponible y a su versión digital conservada. La validación interna examina configuraciones nominales y familias de cantidad de celdas en Y; no representa validación en otra campaña, material o proceso de fabricación. El EDA previo utilizó el conjunto completo, por lo que la comparación tiene carácter exploratorio y posible sesgo de selección de hipótesis. La comparación adicional de cinco regresores se conserva como antecedente; el aporte central de este informe es la representación de las entradas, no una búsqueda de algoritmos o hiperparámetros.

2. Contexto experimental y comprensión de los datos

2.1 Descripción del experimento

La fuente académica es la tesis doctoral de Enrico Venditti, de la Università degli Studi di Sassari, cuya portada consigna el año académico 2024/2025. El capítulo experimental describe especímenes de poliamida fabricados por sinterización láser selectiva, diseñados en SolidWorks, con dimensiones exteriores nominales de 210×70 mm. Se variaron las alturas de fibras y pivotes y la cantidad de celdas en Y, buscando una masa idéntica o similar; el archivo no contiene masas medidas para verificar esa condición individualmente [1].

El protocolo documenta tracción con carga y descarga, velocidad de desplazamiento de 15 mm/min y niveles nominales separados por 10 mm. Descargar significa reducir la solicitación, no acreditar un ensayo de compresión. Se registró la respuesta fuerza–desplazamiento y el sonido de las roturas. La documentación consultada no identifica marca, modelo ni sensores del equipo; no se trasladan datos instrumentales de otros artículos a esta campaña. El archivo MATLAB proporciona resúmenes y matrices por ciclo o evento, no las series instrumentales completas.

2.2 Unidad de análisis

La unidad operativa es el *caso experimental* identificado por `Case_n`. No se presupone que identificadores diferentes certifiquen especímenes físicos independientes: faltan metadatos concluyentes de réplica y lote. La fuente contiene 27 casos; la tabla supervisada utiliza 26 con objetivo observado, al excluir únicamente el caso 2 de los análisis que requieren esa respuesta. La exclusión no elimina su geometría de la fuente ni se interpreta como ausencia de falla.

Las familias analíticas $Y = 4$, $Y = 5$ y $Y = 6$ agrupan casos con igual cantidad de celdas en esa dirección. Esta denominación es distinta de los dos conjuntos ortogonales de fibras de cada retículo. Las combinaciones (n_Y, h_f, h_p) definen 24 grupos nominales en la tabla supervisada. Los pares 19/25 y 24/27 comparten esos factores, pero difieren en otros atributos y no son réplicas verificadas. Mantenerlos juntos durante la validación reduce una dependencia identificable; no controla lotes desconocidos. Los ciclos de un caso tampoco se convierten en nuevas filas independientes para predecir su primera falla.

2.3 Variables de entrada

La Tabla 1 contiene las diez columnas geométricas admitidas. Sus nombres originales se conservan para trazabilidad; el notebook utiliza etiquetas en español. Son descriptores declarados de diseño, no una certificación de dimensiones medidas después de fabricar cada pieza.

Tabla 1: Entradas originales, unidades e interpretación. Todas tienen rol de predictor previo al ensayo.

Columna original	Unidad	Interpretación
`n_cells_Y`	conteo	Celdas en Y; descriptor de arquitectura.
`Fiber_height`	mm	Altura h de la sección de fibra.
`Fiber_base`	mm	Ancho b de la sección de fibra.
`Fiber_total_length`	mm	Longitud total declarada de fibras.
`Fiber_total_volume`	mm^3	Volumen declarado de fibras, V_f.
`Pivot_height`	mm	Altura de los conectores.
`Pivot_radius`	mm	Radio de pivote; constante en esta campaña.
`Pivot_total_number`	conteo	Cantidad total declarada de pivotes.
`Pivot_total_volume`	mm^3	Volumen declarado de pivotes, V_p.
`Sample_total_volume`	mm^3	Volumen CAD del espécimen; distinto de $V_f + V_p$.

Fuente: diccionario del repositorio y tabla analítica curada. La retirada del radio se aprende en entrenamiento; la columna original se conserva.

2.4 Variable objetivo

El objetivo $y_i = F_{\mathrm{FF},i}$ corresponde a `First_Failure_Load_N`, fuerza en newtons asociada al primer evento de rotura de una fibra o un pivote según el resumen experimental [1]. La regresión estima $F_{\mathrm{FF}} = f(\mathbf{x}) + \varepsilon$, donde $\mathbf{x}$ representa geometría previa y ε recoge variación no explicada y limitaciones de medición y modelado. Un residuo observado, $y_i - \widehat{y}_i$, no identifica por separado esas contribuciones.

La primera falla no equivale a colapso total ni necesariamente al máximo de la curva. `Ultimate_Load` es la carga terminal reportada; desplazamientos y energías son otras respuestas. Ninguna se admite como entrada, aunque presente asociación con el objetivo. Tampoco se predice aquí el instante, la localización ni el componente que se rompe. Existen diferencias entre algunos

resúmenes y picos de fichas documentales; se conserva el objetivo digital sin reemplazarlo por una magnitud de definición potencialmente distinta.

2.5 Procedencia y trazabilidad

La ingesta extrae asignaciones numéricas literales de `dati_campagna_venditti.m` sin ejecutar MATLAB. La curaduría convierte tipos, comprueba identificadores y conserva la frontera entre predictores y respuestas. El experimento utiliza `data/processed/preliminary/model_table.csv`, cuyo SHA-256 registrado es `2d0a17f5...defa21f8`; el valor completo se presenta en reproducibilidad. La carpeta `preliminary` contiene una copia identificable de una ejecución histórica, no datos simulados.

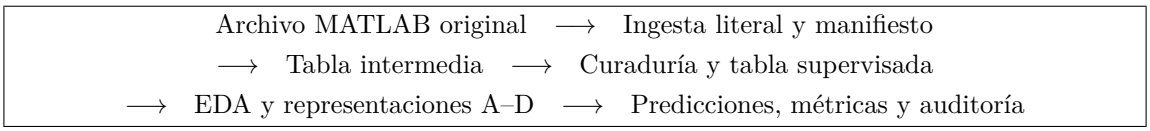


Figura 1: Trazabilidad del procesamiento existente. Los documentos experimentales verifican significado y unidades; las cifras del análisis proceden del archivo digital conservado. Los identificadores permiten enlazar artefactos sin incorporarse a los predictores.

3. Metodología de análisis exploratorio

3.1 Auditoría de calidad

La tabla supervisada no presenta faltantes geométricos, identificadores repetidos ni filas exactamente duplicadas. El objetivo ausente no se imputa. Los factores nominales repetidos se conservan sin promediarlos, pues no se conoce su condición de réplica. La conciliación con la tesis detectó diferencias en anchos, alturas y algunos volúmenes; destacan las incidencias de pivotes de los casos 23, 25 y 26. La fuente digital queda intacta, dado que una discrepancia no establece cuál documento representa la geometría definitiva.

Las reglas univariadas IQR y MAD no marcaron atípicos en geometría ni en el objetivo. Esto no garantiza ausencia de observaciones influyentes: el diagnóstico OLS del EDA asignó distancias de Cook de 0,332 y 0,183 a los casos 1 y 3. Son señales dependientes de esa formulación, no pruebas de error experimental. No se aplicaron eliminación de extremos, winsorización ni correcciones automáticas. La sensibilidad de los resultados se estudia posteriormente sobre errores fuera de muestra, con sus límites explícitos.

3.2 Análisis univariado

La carga de primera falla varía entre 47,55 y 215,52 N; su mediana es 101,89 N y el rango intercuartílico, 118,49 N. Las medianas por familia son 67,12, 100,77 y 205,34 N para $Y = 4, 5, 6$, respectivamente. Esta separación organiza gran parte de la variación observada y justifica informar errores por arquitectura, además del agregado global. No constituye un efecto aislado de aumentar celdas: cambian simultáneamente otros descriptores del diseño.

Las entradas mezclan conteos, longitudes y volúmenes; sus escalas afectan la penalización de Ridge si no se estandarizan. El radio vale 0,5 mm en todos los casos y no permite estimar una relación con la respuesta. Se distingue así una ausencia de variación de una ausencia de

relevancia física. El EDA tampoco justificó transformar indiscriminadamente todas las columnas: reducir asimetría en una magnitud no implica mejorar su utilidad predictiva.

3.3 Relaciones bivariadas

La cantidad de celdas presenta Pearson $r = 0{,}9360$ y Spearman $\rho = 0{,}9307$ con la primera falla. Longitud de fibras y cantidad de pivotes comparten $\rho = 0{,}9307$, porque codifican las mismas familias observadas. El volumen CAD tiene $r = 0{,}7727$ y $\rho = 0{,}7994$ globales, pero su asociación de rangos condicionada por familia es $-0{,}2647$. Esta última correlaciona rangos globales después de restar su media dentro de cada familia. Por tanto, interpretar la relación agregada como un efecto local de volumen sería injustificado.

Los volúmenes declarados satisfacen $V_f + V_p = 6524{,}01$ mm^3 y no equivalen al volumen CAD. La correlación de la razón logarítmica con la carga cambia de 0,8280 global a $-0{,}4773$ condicionada. Los momentos $bh^3/12$ y $hb^3/12$ presentan asociaciones condicionadas de 0,0163 y $-0{,}0753$: su propuesta no se fundamenta en una alta correlación marginal, sino en una expansión dirigida de la representación. Los contrastes condicionados de volúmenes no superan el criterio $q_{\mathrm{BH}} < 0{,}05$ ($q = 0{,}0624$). La selección de hipótesis es, por ello, exploratoria.

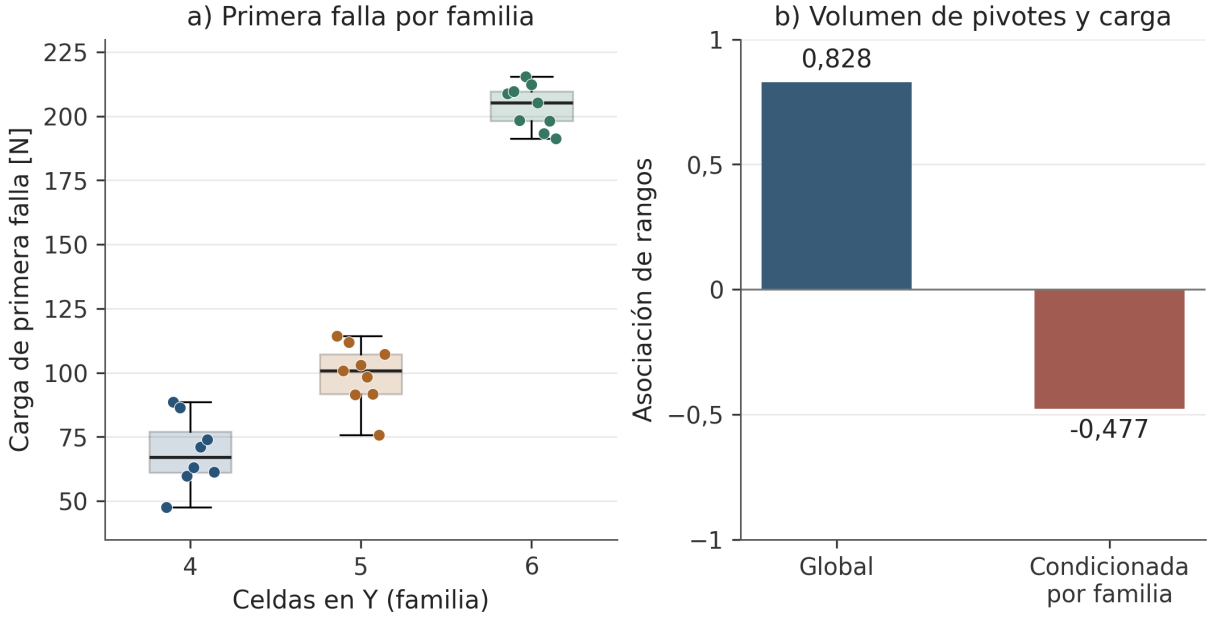


Figura 2: Carga de primera falla por familia y asociaciones de volumen de pivotes con el objetivo. El coeficiente condicionado corresponde a rangos globales residualizados por familia; no es un promedio de correlaciones. Fuentes: tabla analítica y asociaciones del EDA.

3.4 Síntesis EDA–Feature Engineering

La Tabla 2 articula observación, interpretación e intervención. Una asociación descriptiva propone una pregunta; la comparación predictiva determina si la representación ayuda bajo el protocolo elegido. Como el EDA precede a la validación y usa todos los objetivos disponibles, ajustar correctamente el pipeline no elimina ese sesgo previo de selección [4].

Tabla 2: Vinculación entre evidencia exploratoria y decisiones de ingeniería de características.

Hallazgo EDA	Evidencia	Interpretación	Necesidad	Acción FE
Forma de sección	Momentos con ρ condicionado próximo a cero	Sin asociación condicionada fuerte; hipótesis geométrica	Evaluar términos no lineales dirigidos	Añadir ambos momentos en B
Proporción de componentes	Log-razón: ρ global 0,8280; condicionado $-0,4773$	Asociación depende de familia	Contrastar representación relativa	Añadir $\ln(V_p/V_f)$ en C
Dependencias de diseño	$V_f + V_p$ constante; longitud y pivotes asociados a familia	Descriptores dependientes	Probar parsimonia sin imponerla	Retirar un bloque de tres columnas en D
Escalas y constante	mm, mm^3, conteos; radio 0,5 mm	Penalización sensible a unidades	Ajuste comparable y sin fuga	Filtrar constantes y escalar dentro de cada entrenamiento
Dependencia y momento de medición	Factores repetidos; respuestas posteriores	Riesgo de evaluación optimista	Separar grupos y limitar entradas	Agrupar configuraciones; excluir respuestas e identificador

Fuente: tablas de asociaciones, identidades, representaciones y matriz EDA–FE del repositorio. Los coeficientes son descriptivos; no expresan causalidad.

4. Feature Engineering guiado por EDA

4.1 Justificación

Para Ridge, una transformación determinística puede aportar capacidad de representación sin incorporar información experimental nueva. Con ancho y altura separados, una combinación lineal $\beta_b b + \beta_h h$ no reproduce en general los productos cúbicos bh^3 y hb^3. Añadirlos permite estimar una función lineal en un espacio ampliado, aunque no lineal respecto de las dimensiones originales. Se evita una expansión polinómica indiscriminada: los términos evaluados corresponden a fórmulas geométricas identificables y a hipótesis ya formuladas.

La regularización reduce coeficientes, pero depende de la representación y de la escala [5]. Dos conjuntos algebraicamente relacionados pueden producir distintas predicciones penalizadas. Por ello, retirar descriptores dependientes constituye una prueba de parsimonia, no una mejora garantizada. Esta distinción es decisiva para interpretar el resultado negativo de la variante reducida.

4.2 Características originales

La referencia A parte de las diez entradas de la Tabla 1. El ancho de fibra se incluye expresamente, porque está disponible y alimenta las transformaciones posteriores. El filtro entrenado elimina el radio constante y deja nueve predictores efectivos. La matriz geométrica original centrada tiene rango siete entre esas nueve columnas variables; esta dependencia limita la interpretación individual de coeficientes, aunque Ridge permita ajustar el sistema. El identificador del caso nunca forma parte de esta matriz.

4.3 Características derivadas

El primer bloque incorpora los segundos momentos de área de una sección rectangular ideal respecto de sus ejes centroidales:

$$I_{bh^3} = \frac{bh^3}{12}, \qquad I_{hb^3} = \frac{hb^3}{12}, \tag{1}$$

con b, h en mm e I en mm^4. Describen la distribución geométrica de sección en dos orientaciones. La literatura de pantógrafos sustenta considerar geometría relacionada con flexión [2, 3]; sin embargo, estos descriptores no son rigidez EI medida, fuerzas aplicadas adicionales ni criterios de fractura. No se dispone de evidencia para asignar un eje dominante a cada primera rotura. Ambos se prueban conjuntamente, de modo que el contraste B–A no identifica su contribución individual.

Como control del cálculo, el caso 1 tiene $b = 2{,}4$ mm y $h = 1$ mm: las fórmulas producen 0,2 y 1,152 mm^4. La coincidencia con el pipeline verifica implementación, no validez mecánica ni mejora predictiva. Los momentos pueden ser redundantes con otras medidas y amplifican discrepancias del ancho o altura; su beneficio debe juzgarse con predicciones reservadas.

El segundo bloque añade

$$L_{p/f} = \ln\left(\frac{V_p}{V_f}\right) = \ln(V_p) - \ln(V_f), \qquad V_p, V_f > 0. \tag{2}$$

La razón es adimensional y expresa proporción de volúmenes declarados. Su implementación usa diferencia de logaritmos, equivalente en el dominio positivo. No estima reparto de fuerzas ni asegura normalidad. Dada la complementariedad de volúmenes, no aporta una medición independiente: propone otra función no lineal de cantidades existentes. La inversión entre asociación global y condicionada motiva evaluarla sin anticipar una mejora.

La intervención final elimina longitud total de fibras, número de pivotes y volumen de fibras como columnas directas. Se conserva el conteo de celdas como descriptor de arquitectura y el volumen de fibras continúa siendo necesario para calcular $L_{p/f}$. Por tanto, D reduce entradas al regresor, pero no elimina la necesidad de disponer de ese volumen en el contrato de datos. El contraste evalúa conjuntamente simplificación y cambio de parametrización penalizada; no demuestra que cada columna retirada sea prescindible.

4.4 Transformaciones estadísticas

El pipeline aplica contrato geométrico, imputación, construcción de representación, filtro de varianza nula, estandarización y regresión [6]. Las fórmulas y la lista de columnas de D son determinísticas. Las medianas de imputación y el filtro se calculan en entrenamiento; la imputación es una contingencia sin valores rellenados en la geometría actual. El objetivo nunca se imputa. El escalamiento utiliza

$$z_{ij} = \frac{x_{ij} - \mu_{j,\text{train}}}{\sigma_{j,\text{train}}}, \tag{3}$$

con desviación poblacional del entrenamiento. Los casos reservados reutilizan esos parámetros. No se aplicaron codificación one-hot, transformación del objetivo, remuestreo sintético, selección supervisada adicional ni recorte de extremos. Los conteos conservan su valor numérico.

4.5 Control de leakage

El contrato admite exclusivamente las diez columnas geométricas, rechaza respuestas e identificadores y verifica positividad, finitud y conteos enteros. Cada partición crea un pipeline independiente; sus medianas, variables retenidas, medias, escalas e identificadores quedan registrados. La auditoría contrasta esas estadísticas con el entrenamiento efectivo y verifica que no se compartan casos ni grupos entre ajuste y evaluación. Las características derivadas no consultan el objetivo ni variables posteriores al ensayo.

Estos controles sustentan ausencia de fuga de procesamiento en las rutas auditadas; no equivalen a independencia experimental certificada ni a ausencia absoluta de sesgo. Persiste el uso del conjunto completo para generar hipótesis, además de las incertidumbres de procedencia geométrica y lotes. La evidencia predictiva debe interpretarse dentro de esos límites.

4.6 Feature sets experimentales

Las variantes son acumulativas (Tabla 3): B se contrasta con A, C con B y D con C. Cada paso modifica un bloque documentado, manteniendo el modelo, sus parámetros y las observaciones. No es un diseño factorial ni una ablación individual de todas las características.

Tabla 3: Representaciones efectivamente evaluadas con Ridge. Los conteos corresponden a columnas tras retirar el radio constante.

Set	Originales	Añadidas	Excluidas	Intervención	Justificación
A (9)	Geometría original	Ninguna	Radio constante	Referencia	Error con dimensiones declaradas
B (11)	Igual que A	Dos momentos	Radio constante	B–A: un bloque	Expansión no lineal de sección
C (12)	Igual que A	Momentos y $L_{p/f}$	Radio constante	C–B: una razón	Proporción entre componentes
D (9)	A menos tres columnas	Igual que C	Radio, longitud, número de pivotes y V_f directo	D–C: reducción de bloque	Parsimonia y parametrización

Fuente: configuración y auditoría de transformaciones. La exclusión del radio pertenece al procesamiento común; V_f sigue siendo insumo de la razón en D.

La construcción permite contrastar dos cuestiones distintas: si una función de la geometría mejora la aproximación de Ridge y si una representación reducida conserva el desempeño. Una característica físicamente interpretable no se adopta por su nombre, y una dependencia algebraica no obliga a eliminarla. Ambas decisiones requieren la evidencia comparativa desarrollada en las secciones siguientes.

5. Diseño experimental y protocolo de validación

5.1 Naturaleza del experimento

Se realizó una comparación computacional controlada de representaciones. La unidad de contraste es la diferencia de error entre predicciones de los mismos casos reservados. Compartir objetivo, observaciones, particiones y estimador permite atribuir las diferencias numéricas a la modificación documentada del pipeline. No se aleatorizaron ensayos físicos ni se estimaron efectos causales del tamaño de fibra sobre la rotura.

5.2 Definición de variantes

A establece la referencia con geometría original; B añade el bloque de momentos; C añade la razón logarítmica sobre B; D retira tres columnas directas de C. El análisis incremental usa B–A, C–B y D–C; la tabla principal también informa la distancia de cada conjunto respecto de A. El control auxiliar *Dummy* predice la media del entrenamiento. No se denomina baseline de características a ese control: sirve para comprobar cuánto aporta la geometría frente a una predicción constante.

La regla registrada exige simultáneamente reducir MAE al menos 5 %, mejorar en al menos 60 % de los grupos, no aumentar RMSE y no aumentar el MAE agregado del protocolo secundario por familia. Si únicamente mejora el MAE principal, la intervención permanece en evaluación; si empeora, se descarta. Son umbrales operativos del proyecto, no tolerancias mecánicas ni pruebas de significancia. La configuración los documenta, pero no constituye un registro prospectivo independiente.

5.3 Modelo utilizado

Ridge ajusta una relación lineal en las características transformadas y penaliza la magnitud de sus coeficientes [5, 7]:

$$(\widehat{\beta}_0, \widehat{\boldsymbol{\beta}}) = \arg\min_{\beta_0, \boldsymbol{\beta}} \left[\sum_{i \in T} \left(y_i - \beta_0 - \mathbf{z}_i^\top \boldsymbol{\beta} \right)^2 + \alpha \|\boldsymbol{\beta}\|_2^2 \right], \qquad \alpha = 1. \tag{4}$$

El intercepto no se penaliza. Se fijaron `solver=svd`, intercepto habilitado y escalamiento estándar. La descomposición SVD es pertinente ante las dependencias lineales verificadas. No hubo búsqueda de hiperparámetros ni selección del mejor α en este sprint; la igualdad de parámetros delimita el efecto de cambiar la representación.

5.4 Estrategia de validación

El protocolo principal aplica *LeaveOneGroupOut* (LOGO) a la combinación (n_Y, h_f, h_p) [8]. Sus 24 particiones reservan una configuración completa cada vez: 22 grupos contienen un caso y dos contienen dos. Los entrenamientos incluyen 25 o 24 casos, respectivamente. Los pares nominales se mantienen juntos para evitar que una misma combinación aparezca simultáneamente a ambos lados de la partición. La geometría reservada puede compartir familia con el entrenamiento; por tanto, esta evaluación no demuestra transferencia a otra arquitectura completa.

El protocolo secundario reserva sucesivamente $Y = 4$, $Y = 5$ y $Y = 6$. Evalúa ocho, nueve y nueve casos, con 18, 17 y 17 casos de entrenamiento. Cada observación recibe una predicción fuera de muestra (OOF) por protocolo y variante. Las listas de casos son idénticas para A–D y están guardadas en `particiones.json`. LOGO no usa barajado; la semilla 42 identifica la configuración general, pero ni el particionado ni Ridge con SVD dependen de ella. No existe un holdout final independiente.

En cada fold se ajusta el siguiente flujo con los casos de entrenamiento:

$$\text{Contrato de entradas} \to \text{imputación} \to \text{representación A–D} \\ \to \text{filtro de constantes} \to \text{estandarización} \to \text{Ridge}.$$

La evaluación solo transforma y predice con los parámetros ya ajustados [9]. El registro de auditoría conserva índices, medianas, columnas, medias y escalas para verificar esa separación. El agrupamiento trata una dependencia conocida, pero no certifica independencia física donde faltan identificadores de lote o espécimen.

5.5 Métricas

Sea $e_i = y_i - \widehat{y}_i$ el residuo OOF de cada caso evaluado. Las métricas se calculan concatenando las predicciones reservadas:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}e_i^2}, \tag{5}$$

$$\mathrm{MedAE} = \mathrm{mediana}_i(|e_i|), \qquad R^2_{\mathrm{OOF}} = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \overline{y})^2}. \tag{6}$$

MAE, RMSE y MedAE se expresan en newtons. MAE es el error absoluto promedio; RMSE penaliza más los errores grandes y MedAE describe el error absoluto central. R^2 compara la suma de errores con la variabilidad global observada y puede ser negativo. No representa un porcentaje de aciertos. No se calcula ni promedia R^2 en folds unitarios.

Para el contraste $V - R$, $\Delta\mathrm{MAE} = \mathrm{MAE}_V - \mathrm{MAE}_R$; un valor negativo favorece la variante. La reducción porcentual es $100(\mathrm{MAE}_R - \mathrm{MAE}_V)/\mathrm{MAE}_R$. La desviación estándar muestral de MAE entre folds describe heterogeneidad, no un error estándar independiente, pues los entrenamientos se solapan. MAE OOF pondera casos; la media y desviación de MAE por fold ponderan grupos. El tiempo registrado suma ajuste y predicción de los folds.

6. Resultados experimentales comparativos

6.1 Resultados del baseline

A obtuvo MAE de 13,247 N, RMSE de 16,346 N, MedAE de 11,941 N y $R^2_{\mathrm{OOF}} = 0{,}923$. El control de media alcanzó MAE de 56,309 N. La geometría aporta capacidad predictiva bajo reserva de configuraciones, aunque la separación entre familias contribuye al buen valor agregado de R^2. Este resultado no garantiza el mismo error para una familia excluida: el MAE de A aumenta a 57,637 N en ese protocolo y su R^2 resulta negativo (Tabla 5).

6.2 Variante 1: momentos de sección

B mantuvo las dimensiones originales y añadió dos funciones geométricas de la sección. El MAE bajó a 12,835 N: 0,412 N o 3,11 % menos que A. RMSE disminuyó 0,143 N, hasta 16,203 N; MedAE fue 11,780 N y $R^2 = 0{,}924$. El tiempo registrado aumentó de 0,290 a 0,683 s. La mejora es pequeña respecto de la dispersión de errores y no acredita un mecanismo de rotura por flexión.

B mejoró el error medio en 15 de 24 grupos (62,5 %), pero no alcanzó el umbral de reducción del 5 %. El MAE al reservar familias aumentó 0,016 N, de 57,637 a 57,654 N. La regla de adopción, aplicada literalmente, conserva B en evaluación. La diferencia secundaria es mínima; su importancia aquí es que no aporta evidencia de transferencia favorable, no que demuestre un deterioro significativo.

6.3 Variante 2 y reducción posterior

C añadió $L_{p/f}$ a los momentos. Su MAE fue 12,914 N, 0,079 N mayor que B (+0,62 %), acompañado de RMSE de 16,327 N. Aunque C sigue 2,51 % por debajo de A, no mejora su referencia inmediata B. La asociación global de la razón con el objetivo no se traduce en beneficio incremental. Se descarta esta adición para el conjunto propuesto, sin afirmar que carezca de utilidad en otros modelos o campañas.

D retiró el bloque de tres columnas directas y produjo MAE de 17,035 N y RMSE de 21,136 N. Frente a C, el MAE creció 4,121 N (+31,91 %); frente a A, 3,788 N (+28,60 %). La representación reducida conservó nueve predictores efectivos, como A, pero con un contenido funcional distinto. La parsimonia nominal no compensó el cambio de parametrización. Este resultado rechaza la retirada conjunta bajo el protocolo evaluado; no estima la importancia individual de cada columna eliminada.

6.4 Tabla comparativa principal

La Tabla 4 procede de la ejecución histórica verificada. La decisión de C y D utiliza su referencia incremental, mientras que la columna Δ permite comparar todos los conjuntos con A.

Tabla 4: Resultados OOF por configuración nominal. Errores y dispersión en N; tiempo en segundos.

Exp.	Features	MAE	RMSE	R^2	Δ vs. A	s_{CV}	Tiempo	Decisión
A	9	13,247	16,346	0,923	0,000	9,677	0,290	Conservar
B	11	12,835	16,203	0,924	-0,412	10,167	0,683	Evaluar
C	12	12,914	16,327	0,923	-0,333	10,267	0,571	Descartar
D	9	17,035	21,136	0,871	3,788	12,703	0,513	Descartar

Fuente: `comparacion_experimentos.csv`. s_{CV}: desviación estándar del MAE de los 24 folds, no intervalo de confianza. Decisiones sujetas a la regla de la sección 5.

6.5 Comparación visual principal

La Figura 3 muestra la ventaja limitada de B y el deterioro de D, junto con el cambio de escala del error al excluir familias. Las barras no llevan intervalos inferenciales: se dispone de una evaluación interna dependiente, no de campañas independientes repetidas. En el protocolo secundario todos los R^2 son negativos; aun así, los MAE son menores que el del control de media del entrenamiento (80,593 N). Son referencias distintas y no deben confundirse.

Tabla 5: Comprobación secundaria: predicciones OOF al reservar familias completas.

Experimento	MAE (N)	RMSE (N)	MedAE (N)	R^2_{OOF}
A	57,637	60,428	64,520	-0,058
B	57,654	60,474	61,761	-0,060
C	57,619	60,528	61,635	-0,061
D	68,834	71,292	72,559	-0,473

Fuente: mismo registro, protocolo `familia`; tres folds. Cada caso se evalúa una vez. No son resultados de entrenamiento.

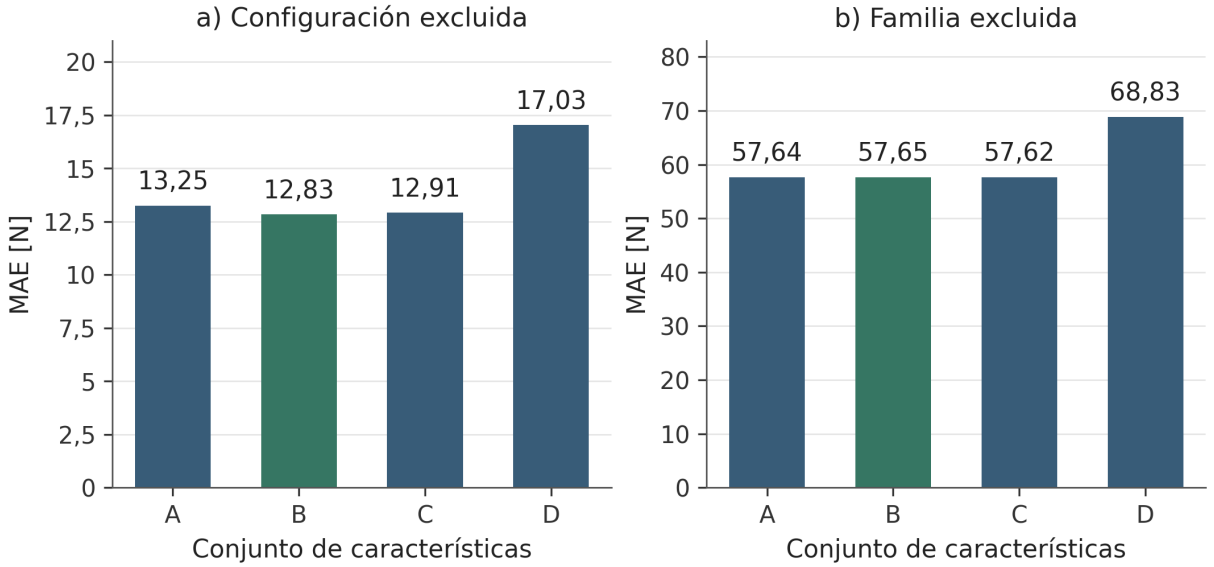


Figura 3: MAE OOF de A–D bajo dos objetivos de generalización. La escala de cada panel se muestra explícitamente. Fuente: predicciones y métricas verificadas de la ejecución de Feature Engineering.

6.6 Diagnóstico de residuales

En B, los casos 1 y 17 fueron sobreestimados en 34,206 y 31,404 N; el caso 22 fue subestimado en 29,640 N (Figura 4). La mejora media no elimina esos errores locales. Por familia, B obtuvo MAE de 15,636, 11,853 y 11,326 N para $Y = 4, 5, 6$. Frente a A empeoró 0,392 N en $Y = 4$ y mejoró 0,653 y 0,885 N en las otras dos. No existe una mejora homogénea entre arquitecturas.

Con residuo definido como observado menos predicho, las medias fueron +4,067, $-9,832$ y +6,909 N. El patrón apunta a sobreestimación media en $Y = 5$ y subestimación en las familias extremas; constituye un diagnóstico descriptivo de calibración local. Al reservar familias, los errores crecen a 52,562, 43,232 y 76,602 N. D, además, genera cuatro predicciones negativas, con mínimo de $-6,798$ N. Se conservaron sin truncar para hacer visible esa incompatibilidad con la magnitud física del objetivo.

6.7 Evaluación de estabilidad

Para cada grupo se calculó $d_g = \text{MAE}_{B,g} - \text{MAE}_{A,g}$. Los contrastes varían entre $-5,423$ y +6,059 N, con mediana de $-0,312$ N (Figura 5). La desviación del MAE entre folds aumenta de 9,677 N en A a 10,167 N en B: una mejora agregada puede coexistir con mayor heterogeneidad. C gana en nueve grupos respecto de B y D en siete respecto de C.

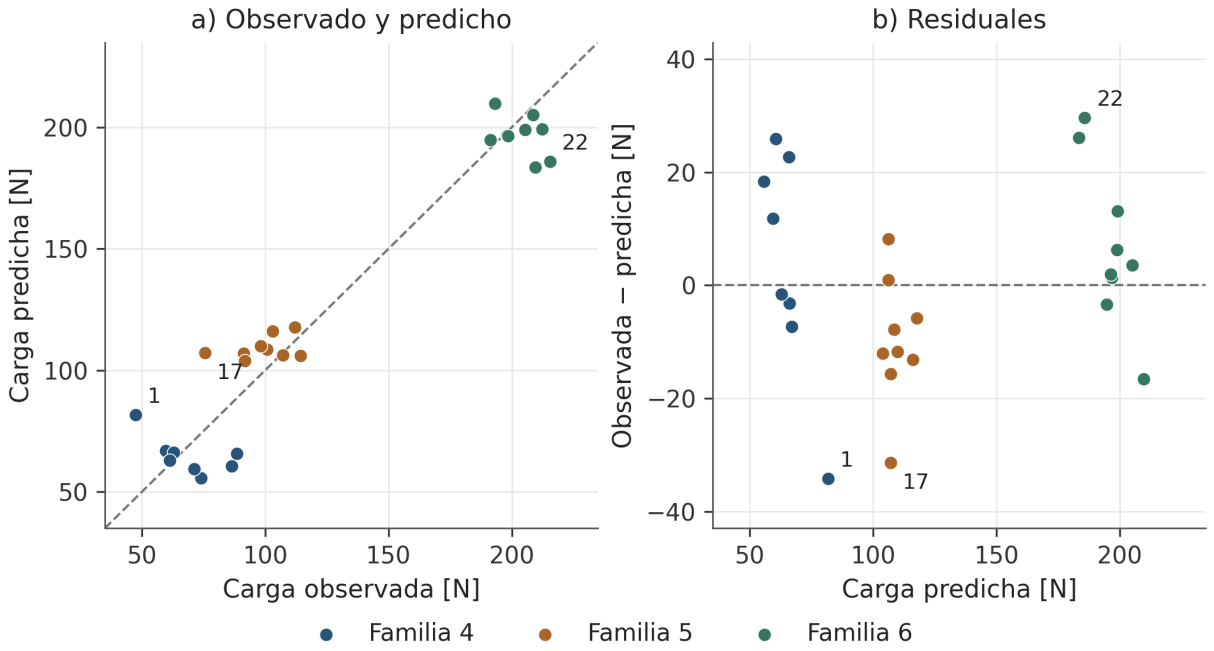


Figura 4: Predicciones OOF y residuales de B en el protocolo principal. La identidad indica predicción exacta y el cero indica ausencia de residuo. Las etiquetas identifican casos concretos; no establecen errores de medición.

La sensibilidad disponible retira cada grupo únicamente del cálculo agregado de errores, manteniendo las predicciones ya calculadas. Bajo esa operación, ΔMAE_{B-A} permanece negativo, entre $-0,671$ y $-0,211$ N. La dirección de la ventaja no depende de puntuar un solo grupo; sin embargo, la operación no reentrena los modelos y los casos retirados pudieron participar en otros ajustes. No constituye un análisis completo de influencia, un intervalo de confianza ni una prueba de superioridad estadística.

6.8 Coste computacional

Los tiempos de A–D fueron 0,290, 0,683, 0,571 y 0,513 s, sumados sobre los folds principales. B añadió aproximadamente 0,392 s a esa ejecución. No se registraron repeticiones de cronometraje, consumo energético ni costo monetario. Que C tarde menos que B no prueba una ventaja computacional inherente: son tiempos cortos de una sola ejecución sujetos al entorno. La decisión depende del error y de la estabilidad, no de diferencias de latencia sin un benchmark específico.

7. Discusión crítica

7.1 Aporte del Feature Engineering

La expansión de momentos aportó una reducción exploratoria de MAE de 3,11 % para configuraciones reservadas. No añadió mediciones; permitió que Ridge representara productos y potencias con coeficientes propios. La razón posterior no agregó beneficio medible frente a B. La retirada conjunta empeoró claramente las métricas: preservar capacidad de representación y regularización fue más útil que minimizar el número de columnas. Dependencia informativa, colinealidad lineal y equivalencia predictiva son conceptos distintos.

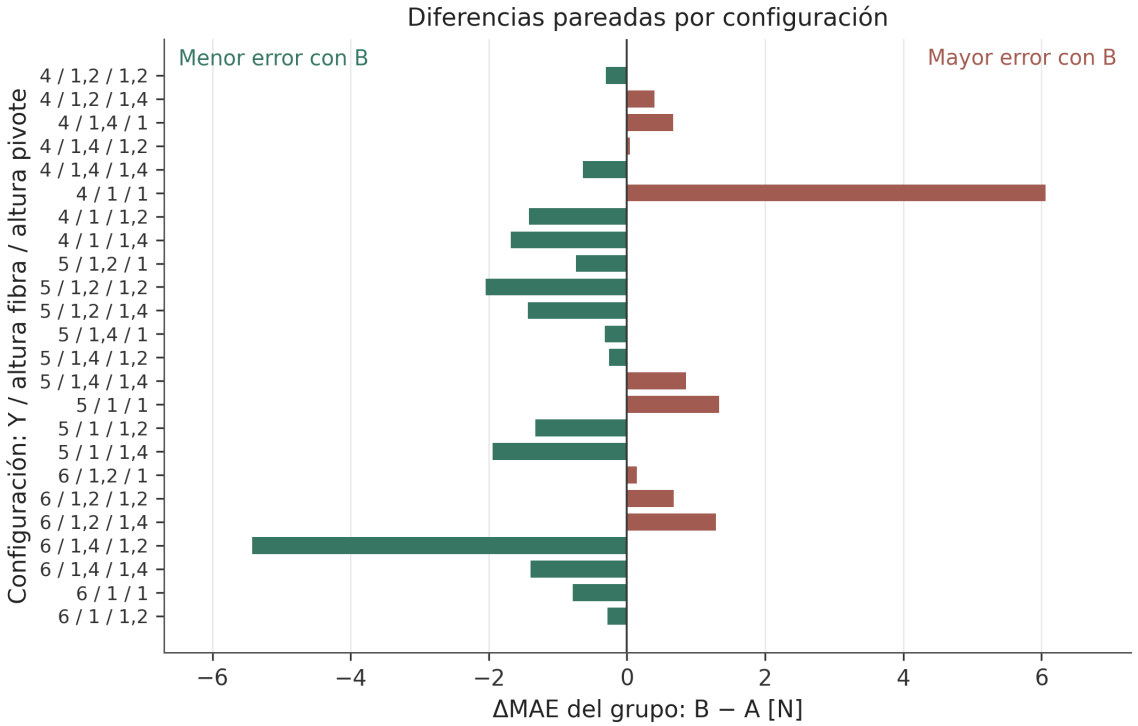


Figura 5: Diferencia pareada de error medio por configuración, B menos A. Valores negativos favorecen B. Cada grupo mantiene idénticos casos de evaluación entre variantes; los entrenamientos de distintos folds se solapan.

La comparación adicional de cinco regresores sobre A se limita al Anexo B. Bosque aleatorio obtuvo MAE de 13,233 N frente a 13,247 N de Ridge, una diferencia de 0,014 N. Esta cercanía no respalda convertir el informe en una selección de algoritmo ganador. Mantener Ridge fijo permite examinar el aporte específico de los conjuntos de características.

7.2 Interpretación mecánica

Los momentos caracterizan geometría de sección compatible con formulaciones que incluyen flexión de fibras, y la razón describe una proporción de componentes [2, 3]. Los datos no permiten convertir esas descripciones en contribuciones separadas de energía ni fuerzas internas. No se conoce para cada evento una etiqueta validada de mecanismo de falla; tampoco se incorpora un módulo elástico medido para estimar EI. La mejora de B respalda explorar esa representación, no identificar la causa de la rotura.

La fuerza externa de tracción es la solicitación documentada. La red puede desarrollar mecanismos internos de extensión, flexión y torsión en sus modelos, pero no se acredita haber aplicado tres ensayos independientes. Una interpretación física defendible mantiene esta separación entre condición de ensayo, descriptor geométrico, mecanismo hipotético y respuesta medida.

7.3 Comparación con el EDA

El EDA atribuye descriptivamente 96,55 % de la variación del objetivo a diferencias entre familias. Esta estructura ayuda a explicar que las asociaciones agregadas sean altas y el error aumente al excluir una familia. La inversión de signo de la razón al condicionar por familia indica que una relación global puede resumir diferencias de arquitectura. C no supera B pese a esa

correlación global elevada; los momentos presentan correlaciones condicionadas cercanas a cero y una mejora pequeña. La utilidad de una representación para un estimador no se determina ordenando correlaciones marginales.

7.4 Robustez y generalización

La evidencia distingue predicción de configuraciones reservadas dentro de familias conocidas y transferencia entre familias. El MAE de B pasa de 12,835 a 57,654 N al cambiar el protocolo. Incluso reservar la familia intermedia no garantiza continuidad útil: arquitectura y otros descriptores cambian conjuntamente. La sensibilidad de scores favorece conservar B como candidata, pero no resuelve ese problema de transferencia ni verifica estabilidad ante otra campaña. El resultado no autoriza desplegar una predicción para geometrías arbitrarias o como límite de seguridad estructural.

7.5 Amenazas a la validez

La validez interna se apoya en mismos casos y particiones, parámetros fijos, auditoría de transformaciones y cálculo desde predicciones OOF. Sus límites son la comparación de bloques, la penalización dependiente de la representación y una única configuración del estimador. El ajuste dentro de entrenamiento previene fuga de procesamiento; la elección de candidatos informada por todo el EDA mantiene sesgo de selección [4].

La dependencia experimental no queda completamente controlada sin metadatos de especímenes y lotes. Las discrepancias entre fichas y MATLAB añaden incertidumbre de medición y procedencia, especialmente en magnitudes elevadas al cubo. La validez externa está restringida a la campaña y al diseño observado; no se verificaron otros materiales o procesos. La ausencia de un holdout independiente y el solapamiento de entrenamientos impiden interpretar la dispersión por fold como incertidumbre inferencial calibrada. Estas limitaciones afectan la fuerza de la conclusión, aunque la comparación computacional sea reproducible.

8. Conclusiones y decisiones del sprint

El EDA permitió identificar escala, constantes, dependencias de diseño y diferencias entre asociaciones globales y condicionadas; esos hallazgos se tradujeron en hipótesis explícitas de representación. La incorporación de dos momentos produjo el menor MAE del contraste principal, pero la ganancia de 0,412 N no alcanza todos los criterios de adopción y no se conserva como ventaja al reservar familias completas. La complejidad crece de nueve a once predictores sin incorporar mediciones nuevas.

La decisión es **mantener A como baseline** y **mantener B en evaluación**. Se **descarta la adición de C respecto de B** y la **reducción de D respecto de C** para esta configuración, con deterioros de 0,079 y 4,121 N, respectivamente. No se adopta una sustitución definitiva. La sensibilidad por omisión de scores preserva la dirección de B–A, pero no establece superioridad estadística ni transferencia externa.

El siguiente sprint debe resolver primero la correspondencia documental de geometrías y la identidad de réplicas y lotes. Después conviene congelar A y B y evaluar ambos sobre ensayos independientes de configuraciones y familias definidas antes de observar sus respuestas,

con idéntico pipeline. Si aún no se dispone de esa ampliación, un análisis de influencia con reentrenamiento puede precisar la estabilidad interna, declarándolo exploratorio; no reemplazaría la validación externa. La prioridad es comprobar la generalización y la calidad del objetivo, antes de ampliar transformaciones o algoritmos.

9. Reproducibilidad

El informe se construye en la rama `sprint-semana-6` de repositorio de la investigación, desde el commit de Feature Engineering `8fdb7961d7eaaaebd9651d0b9a044168893d448a`. La ejecución de referencia terminó el 17 de octubre de 2026 a las 00:45:30 UTC. Este informe consolida esa ejecución; no mezcla métricas recalculadas con tiempos de nuevos entrenamientos. La tabla analítica es `data/processed/preliminary/model_table.csv`; su SHA-256 completo es

`2d0a17f54bdc6a6361aaa6e25a57cf67775c7d47a5e2adefb408f114defa21f8`.

El manifiesto registra Python 3.13.5, NumPy 2.5.2, pandas 2.3.0, SciPy 1.16.0, scikit-learn 1.7.0 y Matplotlib 3.10.3. Son versiones declaradas por la ejecución histórica. La configuración fija semilla 42, Ridge $\alpha = 1$, SVD y los dos agrupamientos. Los hashes verifican datos, código normalizado a LF, evidencia del EDA y resultados; la auditoría del informe reconstruyó métricas y estadísticas de entrenamiento desde los artefactos, sin ajustar regresores.

Tabla 6: Trazabilidad compartida de A–D. Cada columna identifica el artefacto reproducible del contraste.

Exp.	Config.	Dataset	Split	Log	Predicciones	Métricas
A–D	C1	D1	S1	L1	P1	M1

Bajo `reports/feature_engineering/`: C1 = `configuracion.json`; S1 = `particiones.json`; L1 = `ejecucion.log`; P1 = `tables/predicciones_oof.csv`; M1 = `tables/comparacion_experimentos.csv`. D1 corresponde a la tabla analítica identificada arriba.

La identificación por `protocolo`, `experimento`, `fold` y `Case_n` permite reconstruir cada contraste. Los errores por fold, decisiones y sensibilidad se guardan en `tables/metricas_folds.csv`, `tables/decisiones.csv` y `tables/sensibilidad_scores.csv`. `auditoria_transformaciones.json` conserva los parámetros ajustados; `manifest.json` documenta la integridad. Los CSV mantienen precisión completa, mientras el informe redondea para lectura.

Desde la raíz, `python -m src.verificar_fe` comprueba la entrega existente. Para reproducir el experimento completo se utiliza `python -m src.reporte_fe -execute`; este segundo comando reentrena y vuelve a generar sus artefactos, por lo que debe ejecutarse en una copia de trabajo destinada a reproducción. Para regenerar únicamente tablas y figuras del informe se ejecutan los dos scripts de `reports/semana_6/`. Las instrucciones de compilación autónoma, hashes y auditoría se distribuyen junto al fuente LaTeX. No se incluyen documentos experimentales privados en el paquete.

Referencias

[1] E. Venditti, "Analisi strutturale per lo studio del danneggiamento in materiali e strutture complesse," Tesis doctoral, Dottorato in Architettura e Ambiente, Università degli Studi di Sassari, 2024/2025, año académico indicado en portada. Copia privada suministrada; cap. 9 y apéndice A. Las páginas citadas cuentan desde la portada del PDF.

[2] E. Turco, M. Golaszewski, I. Giorgio, and L. Placidi, "Can a Hencky-type model predict the mechanical behaviour of pantographic lattices?" in *Mathematical Modelling in Solid Mechanics*, ser. Advanced Structured Materials, F. dell'Isola, M. Sofonea, and D. Steigmann, Eds. Singapore: Springer, 2017, vol. 69, pp. 285–311. [Online]. Available: https://doi.org/10.1007/978-981-10-3764-1_18

[3] E. Turco, A. Misra, R. Sarikaya, and T. Lekszycki, "Quantitative analysis of deformation mechanisms in pantographic substructures: experiments and modeling," *Continuum Mechanics and Thermodynamics*, vol. 31, pp. 209–223, 2019, publicado en línea el 17 de mayo de 2018. [Online]. Available: https://doi.org/10.1007/s00161-018-0678-y

[4] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: https://jmlr.org/papers/v11/cawley10a.html

[5] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970. [Online]. Available: https://doi.org/10.1080/00401706.1970.10488634

[6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html

[7] scikit-learn developers, "Ridge," Documentación de scikit-learn 1.7, consultado: 23 de octubre de 2026. [Online]. Available: https://scikit-learn.org/1.7/modules/generated/sklearn.linear_model.Ridge.html

[8] ——, "LeaveOneGroupOut," Documentación de scikit-learn 1.7, consultado: 23 de octubre de 2026. [Online]. Available: https://scikit-learn.org/1.7/modules/generated/sklearn.model_selection.LeaveOneGroupOut.html

[9] ——, "Common pitfalls and recommended practices: Data leakage," Documentación de scikit-learn 1.7, consultado: 23 de octubre de 2026. [Online]. Available: https://scikit-learn.org/1.7/common_pitfalls.html#data-leakage

[10] M. D. Aylas Barranca, "Análisis predictivo e interpretable de la respuesta mecánica de estructuras pantográficas mediante aprendizaje automático supervisado aplicado a datos experimentales," Plan de tesis, Universidad Nacional de Ingeniería, Lima, Perú, 2026, copia privada suministrada; pp. 18 y 20 (posiciones PDF 24 y 26).

A. Errores por configuración nominal

Cada fila corresponde al fold principal y conserva su numeración registrada. La configuración es (n_Y, h_f, h_p); las alturas están en mm. Los errores son MAE del grupo en newtons. Los folds con dos casos se evalúan conjuntamente, sin separarlos entre entrenamiento y validación. La diferencia final es B–A.

Tabla 7: Errores OOF de los cuatro conjuntos en cada grupo nominal.

Fold	Configuración	Test	A	B	C	D	Δ B–A
1	4 / 1,2 / 1,2	1	7,655	7,349	7,358	6,172	-0,305
2	4 / 1,2 / 1,4	1	17,959	18,359	18,450	18,815	0,399
3	4 / 1,4 / 1	1	22,045	22,716	22,947	25,795	0,671
4	4 / 1,4 / 1,2	1	3,134	3,179	3,177	2,516	0,046
5	4 / 1,4 / 1,4	1	2,174	1,539	1,445	0,277	-0,635
6	4 / 1 / 1	1	28,147	34,206	35,225	34,191	6,059
7	4 / 1 / 1,2	1	27,336	25,918	25,942	25,932	-1,418
8	4 / 1 / 1,4	1	13,505	11,821	12,028	12,279	-1,685
9	5 / 1,2 / 1	1	8,512	7,770	7,851	11,947	-0,742
10	5 / 1,2 / 1,2	1	15,177	13,134	13,101	15,547	-2,043
11	5 / 1,2 / 1,4	1	32,836	31,404	31,407	38,581	-1,433
12	5 / 1,4 / 1	1	6,095	5,777	5,748	8,252	-0,318
13	5 / 1,4 / 1,2	1	12,001	11,740	11,701	17,605	-0,262
14	5 / 1,4 / 1,4	1	0,079	0,936	0,997	6,359	0,857
15	5 / 1 / 1	1	6,828	8,159	8,113	4,046	1,331
16	5 / 1 / 1,2	1	17,035	15,712	15,705	21,821	-1,323
17	5 / 1 / 1,4	1	13,987	12,042	12,066	20,578	-1,945
18	6 / 1,2 / 1	1	25,945	26,087	26,071	36,068	0,142
19	6 / 1,2 / 1,2	1	0,660	1,334	1,362	2,855	0,674
20	6 / 1,2 / 1,4	1	11,881	13,169	13,144	31,134	1,289
21	6 / 1,4 / 1,2	1	7,399	1,975	2,133	5,742	-5,423
22	6 / 1,4 / 1,4	2	6,231	4,836	4,890	4,297	-1,395
23	6 / 1 / 1	2	10,818	10,031	10,131	22,560	-0,787
24	6 / 1 / 1,2	1	29,921	29,640	29,748	42,681	-0,281

Fuente: `reports/feature_engineering/tables/metricas_folds.csv`. Los grupos no constituyen repeticiones independientes del entrenamiento. Se excluye R^2 por fold, al existir evaluaciones unitarias.

B. Comparación secundaria de regresores

Este antecedente utiliza exclusivamente el conjunto A y las mismas particiones. No interviene en la comparación controlada de representaciones ni acredita una selección final de algoritmo. Los tiempos corresponden a una ejecución separada del contraste A–D, por lo que el tiempo de Ridge difiere ligeramente.

Tabla 8: Regresores sobre geometría original, protocolo de configuraciones.

Modelo	MAE (N)	RMSE (N)	R^2_{OOF}	Tiempo (s)
Ridge	13,247	16,346	0,923	0,272
Elastic Net	13,979	17,100	0,915	0,352
SVR con núcleo RBF	15,651	19,096	0,894	0,331
Bosque aleatorio	13,233	16,341	0,923	4,126
Proceso gaussiano	16,058	19,341	0,892	0,248

Fuente: `reports/feature_engineering/tables/comparacion_modelos.csv`. Parámetros fijos; no se realizó búsqueda de hiperparámetros.

Ridge utiliza $\alpha = 1$ y SVD. Elastic Net fija $\alpha = 0{,}1$, razón L1 de 0,5 y máximo de 20 000 iteraciones. SVR usa núcleo RBF, $C = 100$, $\varepsilon = 5$ y `gamma=scale`. Bosque aleatorio utiliza 200 árboles, mínimo de dos observaciones por hoja, semilla 42 y un proceso. El proceso gaussiano usa núcleo Matérn con longitud 3, $\nu = 1{,}5$, $\alpha = 0{,}05$, optimizador deshabilitado y normalización del objetivo dentro de entrenamiento. La configuración exacta está en `config/comparacion_modelos.json`. El protocolo por familia arroja R^2 negativo para los cinco regresores, por lo que la limitación de transferencia no desaparece al cambiar de estimador.

C. Fuentes documentales y archivos de verificación

La fuente experimental de Venditti se consulta por posición de página en el PDF suministrado: portada (1), arquitectura (91), fabricación y dimensiones (94), geometrías (95), protocolo y señales (96–97) y fichas del apéndice A [1]. La provisión académica se consigna en el plan de tesis [10]. Estas fuentes privadas se citan para trazabilidad, sin redistribuir sus archivos. Los datos de instrumentación de otros trabajos no se atribuyen a esta campaña.

El sello institucional procede del *Manual de identidad UNI*, enlazado por el portal oficial. Se reproduce el diseño original sin redibujarlo; el archivo `figures/LOGO_FUENTE.md` conserva URL, página y método de extracción. La fecha de consulta documental del informe es el 23 de octubre de 2026.

El directorio del informe incluye `auditoria_resultados.json`, `trazabilidad_tablas.json` y `figures/manifest_figuras.json`, junto con sus scripts de exportación. El README describe la compilación con pdfLaTeX y BibTeX y la comprobación del PDF. Los archivos `.tex`, la bibliografía y las imágenes bastan para compilar en Overleaf; no se necesita ejecutar modelos ni acceder a los PDF privados. El paquete ZIP conserva esa separación entre fuentes editoriales y evidencia experimental del repositorio.